

基本信息

- 谢佰杰 / 男 / 1998.2 / 上海
- 联系方式：电话（微信）： 18101940148 邮箱： xbj3141@126.com
- 教育经历：中国科学技术大学 本科 少年班学院 计算机专业 （2015.9 - 2019.6）
- 工作经历
 - 某大厂 - 大模型推理优化工程师（2024.2 - 2026.5）
 - 芯盟科技 - 编译器研发工程师（2023.6 - 2023.12）
 - 寒武纪 - 编译器研发工程师（2019.7 - 2023.6）
- 职业技能
 - 精通 C++、Python，熟练掌握 CUDA/cutlass/tilelang 等 GPU DSL 的调优与开发，熟悉 Agent Native 开发范式，善于利用 Skill/Plugin/MCP 构建 AI Agent 工作流。
 - 深入理解 LLM 推理优化全链路，具备 RTP-LLM/BladeLLM/vLLM/SGLang 等多个推理框架的开发与调优经验
 - 深入理解 GPU 硬件架构与 CUDA 编程模型，能精准定位 LLM 端到端性能瓶颈并实施针对性算子优化
 - 深耕 LLM 量化技术（GPTQ/AWQ/TurboQuant/向量量化等），主导产出 4 篇发明专利
- 团队建设：担任新员工导师（师兄），定期主持前沿技术分享

项目经历

- 某大厂 - AMD MI308X 大模型推理加速：支撑 AMD MI308X 千卡集群上线，端到端性能达 NV H20 的 1.3 倍
 - BladeLLM/RTP-LLM AMD 生态基础设施建设：移植并深度调优 AMD 版高性能算子——Page/Flash/ChunkedPrefill Attention、双轴拒绝采样、FusedMoE 等；搭建 CUDA-to-HIP 自动化迁移（HIPify）基础设施，大幅降低 CUDA 生态向 AMD ROCm 平台的迁移成本。
 - CUDA Graph：独立在 RTP-LLM 中为 NVIDIA/AMD 集成 CUDA Graph 功能，消除 Kernel Launch 开销，全系列模型端到端性能提升 1.2%~8%。独立完成隔离内存池设计、现有算子 Graph 兼容性检查和修复、端到端精度调试等关键 C++ 框架级工作。
 - 淘天业务落地支撑：推动 AMD MI308X 在淘天搜推广场景的规模化落地。对目标模型进行端到端性能剖析，精准定位性能瓶颈，通过量化策略、算子融合、算子调优与版本升级等全链路手段，在保障模型精度的同时实现性能达标，完成业务从 NVIDIA/PPU 到 AMD 的无感迁移。
 - 图优化 & 算子融合流水线：面向淘天搜推广业务，设计并实现 Rule-based 计算图匹配机制替代原有 Pattern-based 方案，显著降低图分析与算子开发成本。支持动态 Shape 推导；基于 cuTe 实现模板化算子生成，完成从 TensorFlow 计算图到单一融合 cuTe Kernel 流水线的自动转换。
- 寒武纪 - NPU 框架编译器与工具链开发：构建框架编译器、自研 DSL 及底层编译工具链，支撑 NPU 软件生态
 - 自研 DSL 编译工具链：参与指令集封装与回片验证全流程；设计编译器绕过硬件 Bug 方案，保障芯片早期量产稳定性；探索NPU场景的自动向量化与DCE优化，为后续编译器优化提供技

术预研。

- **TVM 框架适配与编译优化**：负责 MLU270 平台 TOPI 层核心算子适配（Conv2D/BatchNorm/ReLU/Softmax），确保 ResNet50、VGG16 端到端成功落地。基于 TVM 研发领域专用 DSL（Domain-Specific Language）与编译器 Pass，实现算子融合、循环拆分（Loop Tiling/Splitting）等后端优化，提升 MLU270 硬件利用率。